PROJET 11 — PILOTEZ UN PROJET DATA AUGMENTÉ PAR L'IA

Mission 1 — Documentation de la démarche

Amélioration IA du livrable du Projet 6 — Catalogue Bottleneck

Aurélie Dupassieux
Parcours Business Intelligence Analyst — OpenClassrooms
Septembre 2026

1. Objectif de la mission

Ce document présente la démarche suivie pour améliorer, de manière critique et documentée, le livrable Python du Projet 6 (analyse du stock et des ventes du site Bottleneck) grâce à l'intelligence artificielle. Il couvre la veille métier et technologique, le cahier des charges fonctionnel, l'organisation du projet, les tests réalisés, les résultats obtenus, les limites identifiées et les décisions prises.

Le livrable initial (notebook P6) réalise un nettoyage de données rigoureux (9 erreurs identifiées et corrigées) et une détection d'outliers univariée sur la variable prix (Z-score et IQR). L'amélioration proposée porte sur l'ajout d'une couche de détection d'anomalies multivariée, en complément de l'approche existante.

2. Veille métier et technologique

2.1 Besoin identifié

La détection actuelle repose sur des règles statistiques univariées (Z-score, IQR) appliquées uniquement à la variable prix. Une anomalie métier — marge incohérente, stock dormant sur une référence au positionnement premium — peut ne pas être atypique sur une seule variable, mais le devenir lorsque plusieurs variables sont observées simultanément. Ce constat, documenté dans la littérature technique consultée, constitue le besoin d'amélioration retenu.

2.2 Panel de solutions comparées

- Option A (méthode déjà en place) — Z-score et IQR : approche statistique univariée.
- Option B (retenue en complément) — Isolation Forest : approche par apprentissage automatique, multivariée, non supervisée.

2.3 Critères de comparaison

Critère	Z-score / IQR	Isolation Forest
Détection multivariée	Non — variable par variable	Oui — croise plusieurs variables simultanément
Hypothèse de distribution	Normale (Z-score) ou aucune (IQR)	Aucune hypothèse de distribution
Interprétabilité	Élevée — seuil chiffré, lisible	Moyenne — score d'anomalie, nécessite une lecture par comparaison de profils
Robustesse / petits volumes	Bonne	Correcte — variance testée entre exécutions
Temps de calcul	Négligeable	Faible, adapté à un dataset de quelques centaines de lignes
Biais / risque	Sur- ou sous-détection selon le seuil choisi	Sensible au taux de contamination fixé a priori

2.4 Sources consultées

- Rakotomalala R., Université Lyon 2 — support de cours « Isolation Forest » : définition de l'anomalie multivariée.
- Ramakrishnan et al., « Anomaly Detection for an E-commerce Pricing System », Walmart Labs (arXiv, 2019) — cas d'usage retail à grande échelle sur la détection d'anomalies de prix.
- OneStream, documentation technique « Isolation Forest Anomaly Detector » — cas d'usage gestion de stock en environnement retail.
- Support de cours « Anomaly Detection » (traeai.com) — comparatif des forces et limites de Z-score, IQR et Isolation Forest.
- Annielytics, « Isolation Forest Model » — synthèse des cas d'usage et des limites du modèle.

2.5 Décision de veille

Les deux méthodes sont conservées en complémentarité plutôt qu'en substitution : le Z-score/IQR reste le premier niveau de lecture, rapide et interprétable pour un interlocuteur métier ; Isolation Forest est ajouté comme couche additionnelle pour capter les anomalies multivariées structurellement invisibles à l'approche univariée.

3. Cahier des charges fonctionnel

Contexte et parties prenantes

Client fictif : Bottleneck, caviste en ligne. Commanditaire métier : Nicolas, responsable vente. Prestataire : Aurélie Dupassieux, consultante data (ESN Data).

Problématique métier

Fiabiliser et enrichir la détection d'anomalies produit (prix, marge, stock) au-delà des règles statistiques univariées déjà en place, sans perdre l'interprétabilité nécessaire à une décision métier.

Périmètre

- Inclus : les 712 produits du catalogue consolidé disposant d'une correspondance web, sur les variables price, purchase_price, stock_quantity, total_sales, taux_marge.
- Exclus : les règles de nettoyage déjà validées en Projet 6 (erreurs #1 à #9) ; le tableau de bord Power BI, déjà amélioré lors du Projet 9.
- Période couverte : données d'octobre (mois unique disponible).

Contraintes

- Volume de données restreint (712 lignes), impliquant un risque de variance sur un modèle entraîné sur peu d'observations.
- Absence de données personnelles : aucun enjeu RGPD sur ce périmètre (données produit).
- Outillage : rester dans l'écosystème Python / Pandas / scikit-learn déjà utilisé, sans dépendance lourde additionnelle.

Critères de réussite

- Data : retrouver au moins les anomalies déjà identifiées manuellement en Projet 6 sans multiplier les faux positifs.
- Modèle : taux de contamination réglé pour rester dans une plage exploitable manuellement (aligné sur le taux observé avec l'IQR, environ 4 %).
- Opérationnel : temps d'exécution négligeable, code commenté et reproductible.

Mini-plan de formation pour les métiers

Une note d'une page destinée à Nicolas explique, en langage non technique, ce qu'est un score d'anomalie : plus un produit s'écarte du reste du catalogue sur plusieurs critères à la fois, plus son score est élevé. Une grille de lecture accompagne cette note pour distinguer une anomalie « à corriger » (erreur de saisie) d'une anomalie « légitime » (positionnement haut de gamme). La recommandation opérationnelle est qu'une revue humaine reste systématique avant toute action commerciale : l'IA priorise les cas à examiner, elle ne décide pas à la place de l'équipe vente.

4. Organisation du projet

4.1 Découpage en lots

Lot	Statut
Cadrage et veille métier/technologique	Terminé
Cahier des charges fonctionnel	Terminé
Implémentation Isolation Forest	Terminé
Tests de robustesse (stabilité, sensibilité)	Terminé
Revue manuelle des anomalies détectées	Terminé
Documentation formelle	Terminé (ce document)

Lot	Statut
Portfolio professionnel (Mission 2)	À réaliser

4.2 Registre des risques

Risque	Probabilité	Impact	Mitigation
Sur-interprétation d'une anomalie comme une erreur alors qu'elle reflète un positionnement premium légitime	Moyenne	Moyen	Revue humaine systématique avant conclusion
Variance du modèle entre exécutions	Faible	Faible	random_state fixé ; stabilité testée (96,9 % sur deux graines)
Dataset restreint limitant la généralisation	Moyenne	Moyen	Usage cantonné à l'aide au tri, pas à la décision automatique

5. Hypothèses, tests, résultats, limites et décisions

5.1 Hypothèse testée

Une détection multivariée (Isolation Forest) permet d'identifier des anomalies produit invisibles à une détection univariée du prix seul (Z-score/IQR), en particulier des combinaisons prix normal / marge atypique / rotation de stock atypique.

5.2 Protocole de test

- Variables utilisées : price, purchase_price, stock_quantity, total_sales, taux_marge.
- Modèle : IsolationForest (scikit-learn), 200 arbres, contamination fixée à 4,4 % (alignée sur le taux observé avec l'IQR sur le prix seul, pour une comparaison à volume égal), random_state fixé à 42 pour la reproductibilité.
- Test de stabilité : comparaison des anomalies détectées entre deux graines aléatoires différentes (42 et 7).
- Test de sensibilité : variation du taux de contamination (3 %, 5 %, 8 %) pour vérifier un comportement progressif du modèle.

5.3 Résultats

Indicateur	Résultat
Anomalies détectées — IQR (prix seul)	31 produits (4,4 % du catalogue)
Anomalies détectées — Isolation Forest	32 produits (4,5 % du catalogue)
Détectées par les deux méthodes	16 produits
Détectées par Isolation Forest uniquement	16 produits
Stabilité entre deux graines aléatoires (42 / 7)	31 / 32 produits identiques (96,9 %)
Sensibilité au taux de contamination	22 anomalies à 3 % ; 36 à 5 % ; 57 à 8 % — progression cohérente

Le modèle est stable sur deux exécutions à graines différentes et réagit de façon progressive au réglage du taux de contamination, sans rupture brutale — ces deux tests confirment que le comportement du modèle est exploitable en conditions réelles malgré la taille restreinte du dataset.

5.4 Interprétabilité — comparaison des profils

Isolation Forest ne fournit pas de feature importance native, à la différence du Z-score dont le seuil est directement lisible. Pour pallier cette limite, les profils moyens des produits flagués ont été comparés à ceux des produits normaux :

Groupe	Prix moy.	Prix achat moy.	Stock moy.	Ventes moy.	Marge moy.
Anomalies	95,66 €	52,12 €	77,8	7,5	33,5 %

Groupe	Prix moy.	Prix achat moy.	Stock moy.	Ventes moy.	Marge moy.
Produits normaux	29,39 €	15,16 €	20,8	8,1	38,0 %

Le facteur dominant reste le positionnement prix/valeur, cohérent avec le catalogue haut de gamme déjà identifié en Projet 6. Le stock nettement plus élevé chez les produits flagués confirme une hypothèse de sur-stockage sur les références premium à rotation lente.

5.5 Revue manuelle des 16 anomalies détectées uniquement par Isolation Forest

Chaque produit a été examiné individuellement et classé selon la grille de lecture définie dans le cahier des charges.

Groupe 1 — Stock premium à rotation lente : à vérifier avec Nicolas (13 produits)

Douze Champagnes Grands Crus (Mailly, Egly-Ouriet, Gosset, Larmandier-Bernier, Agrapart) et un produit hors catégorie vin (huile d'olive Planeta) partagent un même profil : prix dans la norme du catalogue, taux de marge de 23 % à 31 % — au-dessus de la moyenne Champagne (environ 21 %, déjà constatée en Projet 6) —, stock élevé (68 à 145 unités) et ventes faibles à nulles sur la période. Ce n'est pas une erreur de saisie détectable, mais un signal métier cohérent de sur-stockage sur des références à marge élevée et rotation lente, qui mérite un arbitrage commercial : réduction de l'approvisionnement, mise en avant commerciale, ou repositionnement tarifaire. Le produit 4337 (Champagne Mailly Grand Cru Les Echansons 2007, 0 vente sur la période malgré un stock de 145 unités) constitue le cas le plus marqué du groupe et devrait être examiné en priorité.

Groupe 2 — Succès commercial en entrée de gamme : légitime, insight positif (3 produits)

Trois vins d'entrée de gamme (Château De La Selve, Mas Laval, Moulin de Gassac ; prix de 5,20 € à 9,90 €) affichent une combinaison inverse : marge élevée (37 % à 41 %) et ventes élevées (20 à 36 unités), la plus forte vélocité du groupe des 16. Il ne s'agit pas d'une anomalie à corriger mais d'un signal positif — ces références conjuguent volume et marge — à valoriser auprès de Nicolas comme axe de développement plutôt qu'à traiter comme un problème.

5.6 Limites et biais

- Le dataset ne couvre qu'un seul mois (octobre) : une rotation nulle peut refléter une saisonnalité plutôt qu'un vrai stock dormant, à confirmer sur plusieurs mois si les données sont disponibles.
- Isolation Forest suppose que les anomalies sont rares et distinctes du reste des données ; si des anomalies se regroupent ou ressemblent aux données normales, la performance du modèle se dégrade — hypothèse jugée acceptable ici au vu de la taille des groupes identifiés (13 et 3 produits sur 712).
- Le taux de contamination (4,4 %) a été choisi par alignement sur l'IQR pour permettre la comparaison ; un réglage différent, motivé par un objectif métier propre (ex. capacité de revue de l'équipe vente), donnerait un nombre d'anomalies différent (22 à 57 selon les tests de sensibilité).
- Le produit 4355, anomalie de marge déjà identifiée et exclue en Projet 6, n'apparaît pas dans le dataset consolidé utilisé ici : il n'a donc pas pu servir de vérité terrain pour valider la détection.

5.7 Décision finale

Isolation Forest est intégré au notebook comme couche complémentaire — et non de remplacement — de la détection Z-score/IQR existante. Le code est inséré à la suite de l'analyse des corrélations (étape 5.5 du notebook P6), avec random_state fixé pour la reproductibilité et commentaires expliquant le choix du taux de contamination. Les anomalies détectées sont transmises à Nicolas sous forme de deux listes distinctes (à vérifier / insight positif) plutôt qu'une liste unique d'« anomalies », pour éviter qu'un signal commercial positif soit traité comme un problème à corriger.

5.8 Affinage des réglages après la soutenance

L'évaluation a proposé deux pistes : un Z-score sur données logarithmées et une meilleure maîtrise des hyperparamètres d'Isolation Forest. Elles ont été testées dans une étape 5.8 du notebook, sans modifier les résultats précédents (32 anomalies, 16 propres à Isolation Forest).

- Z-score sur prix logarithmé : l'asymétrie du prix passe de 2,60 à 0,28. Seuls 2 produits dépassent 3 écarts-types (contre 13 en brut), et 1 seul avec l'IQR (contre 31). Une grande partie des « anomalies de prix » du Projet 6 tenait à l'étalement de la distribution plutôt qu'à de vraies anomalies, ce qui confirme la revue métier (positionnement premium cohérent).
- Taux de contamination : les listes sont emboîtées (22, 32, 36 puis 57 produits, chacune reprenant quasi intégralement la précédente). Le classement par score est stable ; le taux décide seulement du nombre de cas à revoir et doit être fixé selon la capacité de revue de l'équipe vente. Le taux de 4,4 % est conservé pour comparer à volume égal avec l'IQR.
- Nombre d'arbres : passer de 200 à 500 arbres améliore la stabilité entre graines (indice de Jaccard moyen de 0,88 à 0,90 au réglage retenu) pour un coût de calcul négligeable : recommandé en production.
- Robustesse : 28 des 32 produits signalés le sont à chaque exécution (10 graines sur 10). Ce sont les cas à traiter en priorité ; les 4 autres sont en limite de seuil.

6. Synthèse recruteur / client

Ce travail illustre une démarche IA critique et pilotée sur un projet déjà livré : identification d'un angle mort méthodologique (détection univariée), veille sourcée pour choisir une solution complémentaire plutôt que de remplacer l'existant, mise en œuvre testée pour la robustesse et la stabilité, et surtout une revue métier qui distingue un signal d'alerte (sur-stockage premium) d'un signal positif (succès commercial en entrée de gamme) — deux lectures qu'un unique score d'anomalie aurait confondues sans l'analyse qui l'accompagne.

Prochaines pistes : étendre l'analyse à plusieurs mois pour distinguer saisonnalité et stock réellement dormant ; fixer le taux de contamination selon la capacité de revue de l'équipe vente ; tester une méthode d'explicabilité dédiée (par exemple SHAP) pour renforcer l'interprétabilité du score auprès des équipes métier.

7. Annexe — Journal des essais IA (traçabilité)

Outil IA utilisé : Claude (assistant IA conversationnel d'Anthropic), comme appui à la veille, à l'écriture du code, aux tests et à la documentation. Chaque essai ci-dessous a été vérifié et validé par mes soins ; les demandes sont reformulées de façon synthétique (formulation d'origine résumée). Aucune donnée personnelle n'a été transmise : le jeu de données est un export commercial de produits (références, prix, stocks, ventes).

Essai	Demande formulée à l'IA (résumée)	Variantes testées	Résultat	Décision et raison
1. Choix de l'axe d'amélioration	« Quelles améliorations IA possibles pour mon notebook P6 ? Compare-les. »	Détection d'anomalies · Nettoyage assisté · Explicabilité · Prise en main de l'outil	4 pistes comparées sur qualité, temps, reproductibilité	Détection d'anomalies retenue : apporte un résultat métier mesurable à partir de données déjà fiabilisées
2. Veille et comparaison des méthodes	« Compare Z-score, IQR et Isolation Forest pour détecter des produits atypiques, sources à l'appui. »	Z-score (|z|>3) · IQR (1,5×IQR) · Isolation Forest	Z-score/IQR : prix seul, très lisibles. Isolation Forest : plusieurs variables à la fois	Isolation Forest ajouté en complément (pas en remplacement) ; Z-score/IQR conservés
3. Implémentation et paramètres	« Écris le code Isolation Forest sur prix, prix d'achat, stock, ventes, marge. »	Taux de contamination 3 %, 4,4 %, 5 %, 8 %	22 / 32 / 36 / 57 anomalies selon le taux	4,4 % retenu : aligné sur l'IQR pour comparer à volume égal ; limite documentée (§5.6)
4. Test de reproductibilité	« Vérifie que le résultat ne dépend pas du hasard. »	Graine aléatoire 42 contre 7	31 anomalies communes sur 32 (96,9 %)	Modèle jugé stable ; graine 42 fixée dans le notebook
5. Lecture des résultats	« Compare ce que trouvent IQR et Isolation Forest, et décris les groupes. »	Comparaison des profils moyens anomalies / produits normaux	31 (IQR) · 32 (IF) · 16 communs · 16 propres à Isolation Forest	Revue manuelle produit par produit des 16 cas (essai 6)
6. Revue humaine des 16 cas	« Résume stock, ventes et marge de chacun des 16 produits. »	Lecture individuelle des fiches produit	13 produits à surveiller (surstockage) · 3 produits en réussite commerciale	Deux listes distinctes transmises au métier ; sans cette étape, risque et bonne nouvelle auraient été confondus
7. Pistes écartées	« Faut-il ajouter une	SHAP · autres	Utile mais plus lourd, sans	Écarté pour l'instant ;

Essai	Demande formulée à l'IA (résumée)	Variantes testées	Résultat	Décision et raison
	explicabilité type SHAP ou un autre modèle ? »	algorithmes non supervisés	gain immédiat pour ce périmètre	inscrit dans les prochaines pistes
8. Affinage après évaluation	« Teste un Z-score sur prix logarithmé et compare plusieurs réglages d'Isolation Forest. »	Z-score et IQR brut contre logarithme · 100, 200, 500 arbres · 4 taux de contamination · 10 graines	Z-score : 13 produits en brut contre 2 en logarithme ; 28 produits sur 32 signalés à chaque exécution ; 500 arbres plus stables	Z-score logarithmé et réglages documentés (étape 5.8) ; taux de contamination à fixer avec le métier