PROJET 11 — PILOTEZ UN PROJET DATA AUGMENTÉ PAR L'IA

Amélioration IA du livrable Bottleneck & portfolio professionnel

Soutenance — Aurélie Dupassieux

Certification Business Intelligence Analyst — OpenClassrooms — Septembre 2026

Sommaire

Mission 1

Amélioration IA du notebook Bottleneck

Veille · Cahier des charges · Implémentation · Résultats · Décisions

Mission 2

Portfolio professionnel

Sélection hiérarchisée de preuves & système de veille intégré

Contexte : reprendre un livrable déjà noté

Le livrable de départ

Notebook du Projet 6 : analyse du stock et des ventes du site Bottleneck. 9 erreurs de données corrigées, détection d'outliers de prix par Z-score et IQR.

La mission

L'améliorer de façon critique et documentée grâce à l'IA : comparer au moins deux options, justifier le choix, tracer les tests et les décisions.

RAPPEL — CE QUE FAISAIT DÉJÀ LE PROJET 6

Trois sources, neuf erreurs corrigées, une base fiabilisée

Fichier	Contenu	Lignes
erp.xlsx	Référentiel produit	825
web.xlsx	Export du site marchand	716 utiles
liaison.xlsx	Correspondance ERP ↔ Web	825

9 erreurs identifiées et corrigées

- Jointure NaN = NaN : 825 → 916 lignes avant correction
- 3 prix négatifs, 2 stocks négatifs, 4 statuts incohérents
- 1 carte cadeau comptée comme un vin, à exclure
- Produit 4355 : marge de -512 %, signalé pour vérification

Ce que cette base fiabilisée a révélé

143 505 € — de chiffre d'affaires en ligne (octobre)

16 620 — bouteilles en stock, 269 507 € immobilisés

37,8 % — de taux de marge moyen

28,5 % — de marge sur le Champagne — la catégorie la plus faible

Le Z-score : à quel point ce prix est bizarre ?

1 Le problème

J'ai 713 prix. Comment repérer automatiquement ceux qui sortent du lot ?

2 L'idée

Je mesure la distance entre chaque prix et le prix moyen, en « pas » d'écart-type.

3 La règle

Si un prix est à plus de 3 pas du prix moyen, je le signale.

prix moyen : 32 € — la courbe représente la répartition des prix ; plus on s'éloigne du centre, plus le prix est atypique



EXEMPLE CONCRET

Prix moyen : **32 €**

Écart-type : **27 €**

Un vin à : **225 €**

Distance = 7 écarts-types → 7 > 3 : signalé

REPÉRER LES PRIX ANORMAUX — MÉTHODE 2

L'IQR : où se trouve la majorité des prix ?

1 Le problème

Même question, mais sans utiliser la moyenne, qui peut être trompeuse.

2 L'idée

Je regarde où se situe la moitié « centrale » des prix, du moins cher au plus cher.

3 La règle

Un prix largement au-dessus de cette zone centrale est signalé.

la « boîte » représente la moitié centrale des prix — tout ce qui dépasse largement à droite est signalé



EXEMPLE CONCRET

Moitié centrale : 14 € à 41 €. Zone élargie, avec tolérance, jusqu'à 84 €.

225 € > 84 € → signalé

SYNTHÈSE — MÉTHODES DU PROJET 6

Des outliers justifiés, pas des erreurs

Z-score

13 produits

seuil |z| > 3, soit environ 113 €

IQR

31 produits

1,5 × écart interquartile, ~4,3 % du catalogue

Conclusion du Projet 6 : outliers justifiés

Les prix élevés correspondent à des grands crus et Champagnes de prestige (Egly-Ouriet, Comtes Lafon, Camille Giroud…), cohérents avec le positionnement haut de gamme de Bottleneck — ce ne sont pas des erreurs de saisie.

Le besoin : une détection d'anomalies qui reste univariée

Le notebook applique le Z-score puis l'IQR uniquement sur la variable **prix**.

Or une anomalie métier peut ne pas être atypique sur une seule variable, mais le devenir en croisant plusieurs signaux : prix normal, mais marge ou stock incohérent.

Ce que la littérature confirme

Un point peut ne pas être atypique au sens de chaque variable, mais le devenir quand on observe l'ensemble des variables simultanément (Rakotomalala, Univ. Lyon 2).

LA SOLUTION AJOUTÉE EN PROJET 11

Isolation Forest : isoler, plutôt que modéliser la norme

Le principe, en une image

Imaginez un jeu où l'on sépare les produits en posant des questions au hasard : « le prix dépasse-t-il X ? », « le stock dépasse-t-il Y ? »

Un produit normal, qui ressemble à beaucoup d'autres, demande plusieurs questions avant d'être isolé seul.

Un produit atypique se retrouve isolé après très peu de questions, parce qu'il ne ressemble presque à rien d'autre : c'est ce qui trahit l'anomalie.

Autrement dit : moins un produit met de « questions » à isoler, plus son score d'anomalie est élevé.

La différence clé avec le Z-score / IQR

Le Z-score et l'IQR posent une seule question : le prix.

Isolation Forest peut poser plusieurs questions à la fois : prix, marge, stock, ventes — et donc repérer un produit qui n'est étrange que par la combinaison de plusieurs critères.

TRAÇABILITÉ DE LA VEILLE

Les sources qui ont guidé ce choix

Rakotomalala — Université Lyon 2	Support de cours théorique définissant l'anomalie multivariée et son intérêt par rapport aux méthodes univariées.
Ramakrishnan et al. — Walmart Labs (arXiv, 2019)	Cas réel de détection d'anomalies de prix à l'échelle d'un grand e-commerçant, avec impact business documenté.
OneStream — documentation technique	Cas d'usage d'Isolation Forest appliqué à la gestion de stock en environnement retail.
Support de cours « Anomaly Detection » (traeai.com)	Comparatif détaillé des forces et limites de Z-score, IQR et Isolation Forest.
Annielytics — synthèse technique	Cas d'usage et limites documentées du modèle Isolation Forest.

VEILLE — DEUX OPTIONS COMPARÉES

Z-score / IQR (en place) vs Isolation Forest

Critère	Z-score / IQR	Isolation Forest
Détection multivariée	Non	**Oui**
Hypothèse de distribution	Normale ou aucune	Aucune
Interprétabilité	**Élevée**	Moyenne
Robustesse petits volumes	Bonne	Correcte, testée
Temps de calcul	Négligeable	Faible

Sources : Rakotomalala (Lyon 2) · Ramakrishnan et al., Walmart Labs (arXiv) · OneStream · Annielytics

CAHIER DES CHARGES FONCTIONNEL

Fiabiliser la détection sans perdre l'interprétabilité

Parties prenantes

Nicolas (responsable vente), commanditaire ; Aurélie Dupassieux, consultante data

Périmètre

712 produits avec correspondance web ; prix, prix d'achat, stock, ventes, marge ; données d'octobre

Contraintes

Dataset restreint (712 lignes) ; pas de donnée personnelle ; écosystème Python déjà en place

Critères de réussite

Retrouver les anomalies déjà connues ; taux exploitable manuellement ; code reproductible

ORGANISATION DU PROJET

Six lots, du cadrage à la documentation

Cadrage & CDC	Implémentation	Tests robustesse	Revue métier	Documentation
Terminé	Terminé	Terminé	Terminé	Terminé

Risque principal

Confondre une anomalie de marge légitime (positionnement premium) avec une erreur de saisie → mitigé par la revue humaine systématique.

IMPLÉMENTATION — RÉSULTATS RÉELS

Isolation Forest sur les 712 produits Bottleneck

31
anomalies IQR
(prix seul)

32
anomalies
Isolation Forest

16
détectées par
les deux méthodes

16
détectées par
l'IA seule

Les 16 anomalies « IA seule » sont invisibles à l'IQR sur le prix : elles combinent un prix normal, une marge au-dessus de la moyenne catégorie, et un stock élevé.

TESTS DE ROBUSTESSE

Un modèle stable, vérifié avant d'être utilisé

Un résultat fiable ?

96,9 %

de résultats identiques quand on relance le modèle une seconde fois — le signal n'est pas dû au hasard

Combien d'anomalies ?

22 → 36 → 57

selon le degré de sensibilité choisi (3 %, 5 %, 8 % du catalogue) — le réglage change la quantité, pas la logique

Comment l'expliquer ?

En comparant la « fiche moyenne » d'un produit signalé à celle d'un produit normal : stock plus élevé, prix plus haut

Un même score, deux histoires opposées

GROUPE 1 — 13 PRODUITS — À VÉRIFIER

Stock premium à rotation lente

12 Champagnes Grands Crus + une huile d'olive. Marge 23–31 % (au-dessus de la moyenne Champagne ~21 %), stock 68–145 unités, ventes faibles à nulles.

Priorité : produit 4337 — 0 vente, 145 en stock

GROUPE 2 — 3 PRODUITS — INSIGHT POSITIF

Succès commercial entrée de gamme

3 vins à moins de 10 €, marge 37–41 % ET fortes ventes (20 à 36 unités). Le meilleur profil marge/volume du lot.

Pas une anomalie à corriger — à valoriser

DÉCISION ET LIMITES

Compléter l'existant, pas le remplacer

Décision retenue

Isolation Forest ajouté au notebook comme couche complémentaire du Z-score/IQR. Anomalies transmises à Nicolas en deux listes distinctes plutôt qu'une liste unique.

Limites identifiées

- Un seul mois de données : rotation nulle ≠ forcément stock dormant
- Le produit 4355 (marge déjà connue) n'est plus dans le fichier consolidé
- Taux de contamination choisi par comparaison, pas par un objectif métier propre

FIN DE LA MISSION 1

Place à la Mission 2 : mon portfolio professionnel

Ce qu'on vient de voir

Un besoin identifié, deux méthodes comparées avec leurs sources, testées, vérifiées manuellement produit par produit.

Ce qui arrive maintenant

Dix preuves de compétences hiérarchisées, en ligne sur GitHub, avec la même exigence de méthode et de transparence.

MISSION 2 — PORTFOLIO PROFESSIONNEL

Dix preuves hiérarchisées, une évolution naturelle

1 · Projet 11 — IA & veille

2 · Projet 7 — Sanitoral Power BI

3 · Projet 9 — Bottleneck data viz

4 · Projet 6 — Bottleneck SQL/Python

5 · Projet 8 — Immobilier Paris

6 · Projet 5 — SportDataPulse

7 · Projet 10 — UOI Games

8 · Mission RGPD — Dev'Immediat

9–10 · MDP & AD International Consulting

Le système de veille méthodologique (comparaison Z-score/IQR vs Isolation Forest) est intégré au portfolio comme preuve de compétence à part entière.

ZOOM SUR TROIS PREUVES

De l'analyse SQL au conseil stratégique

Sanitoral (P7)

104 projets IT/Marketing, alerte à 15 % d'écart, dashboard Power BI multi-profils

+337,5 % de dépassement détecté

Bottleneck (P6 → P11)

Nettoyage de données, puis enrichissement par IA en Projet 11

Un même projet, deux montées en compétence

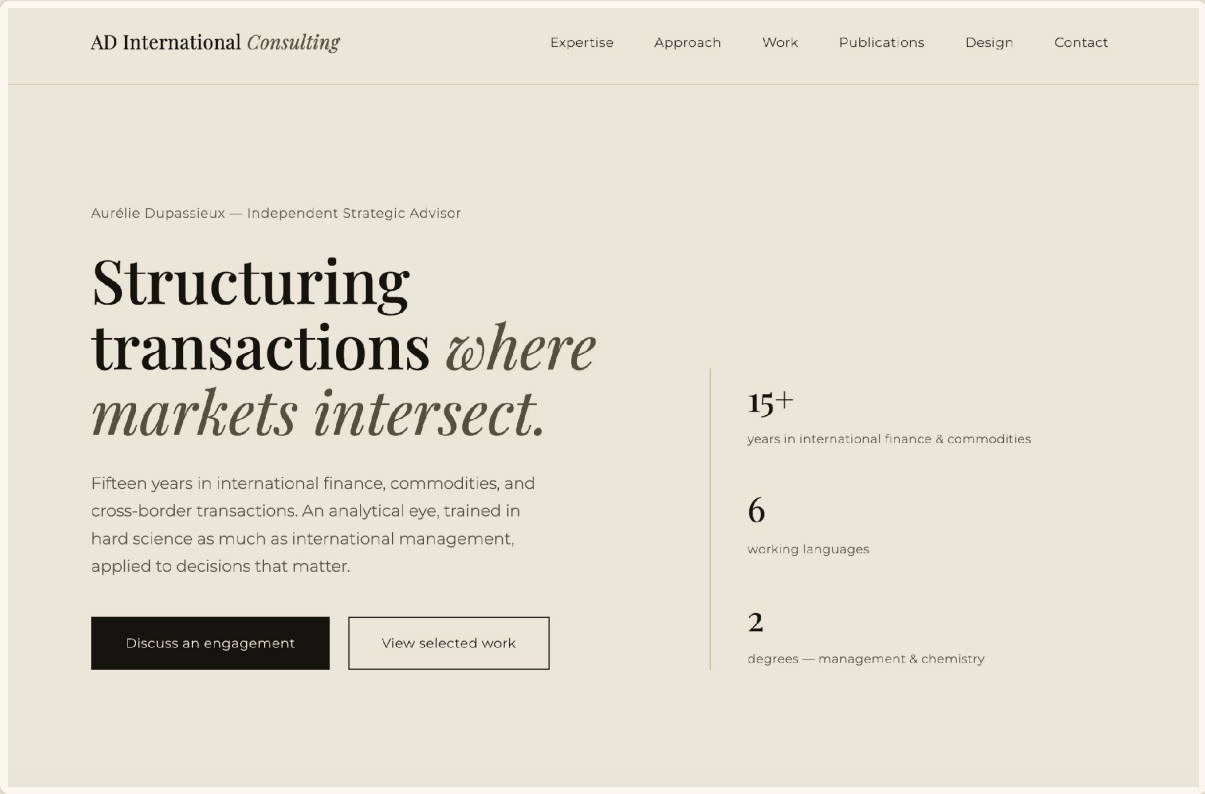
Dashboard MDP (pro)

Modélisation de décision sur une opération de trading pétrole, anonymisée

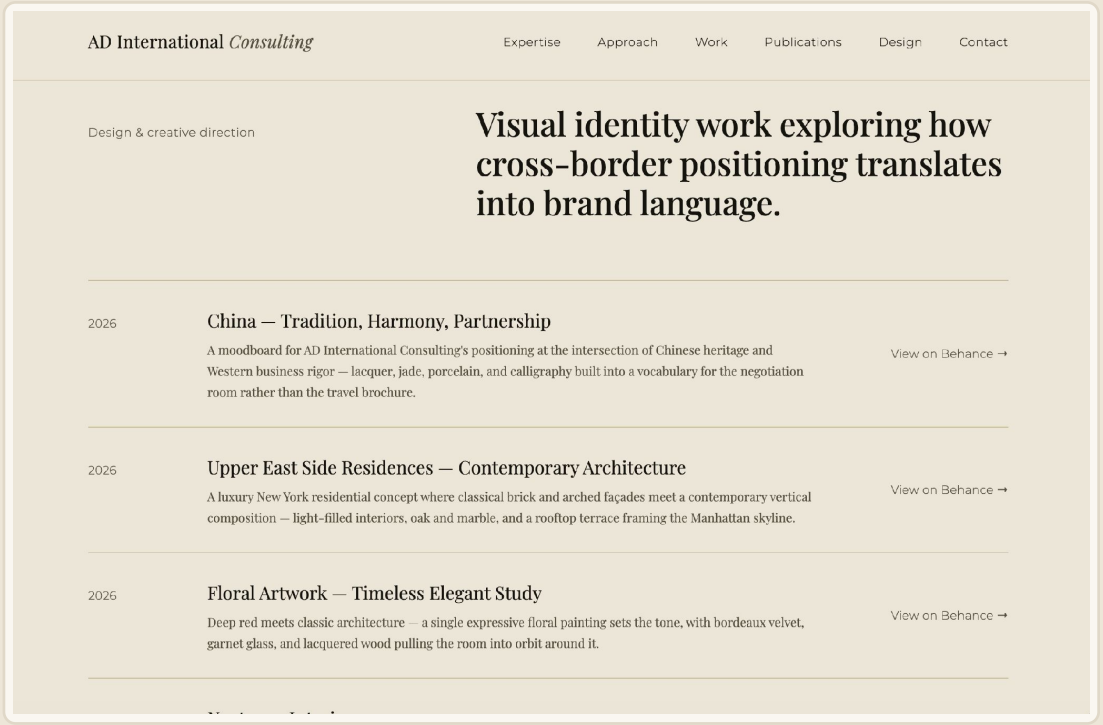
Passerelle finance → data

ZOOM — AD INTERNATIONAL CONSULTING

Une identité professionnelle construite de bout en bout



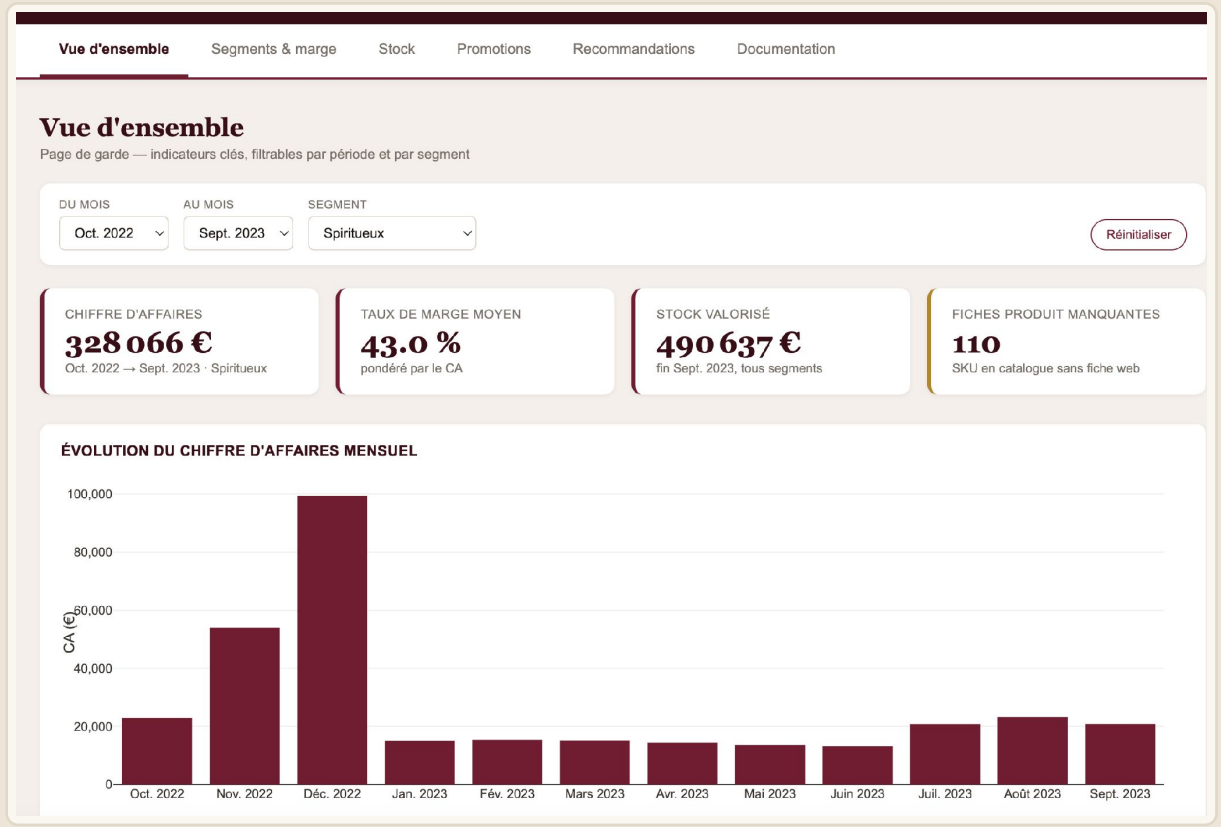
Page d'accueil du site AD International Consulting



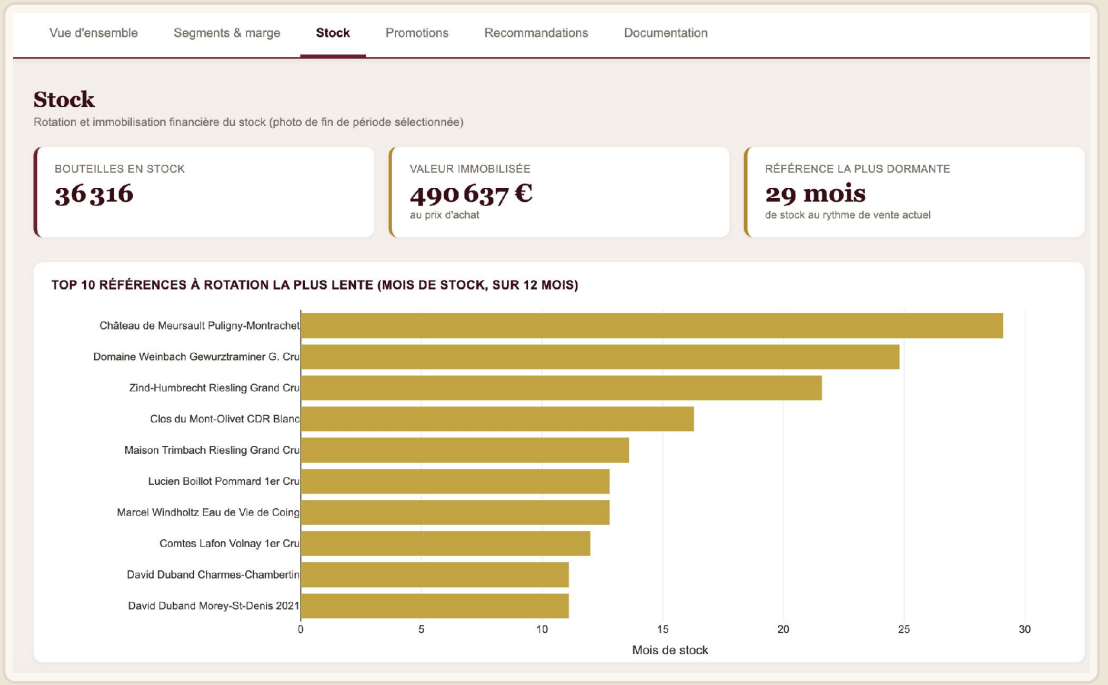
Direction artistique et identité de marque

ZOOM — DASHBOARD BOTTLENECK EN LIGNE

Un dashboard que le client peut ouvrir et manipuler lui-même



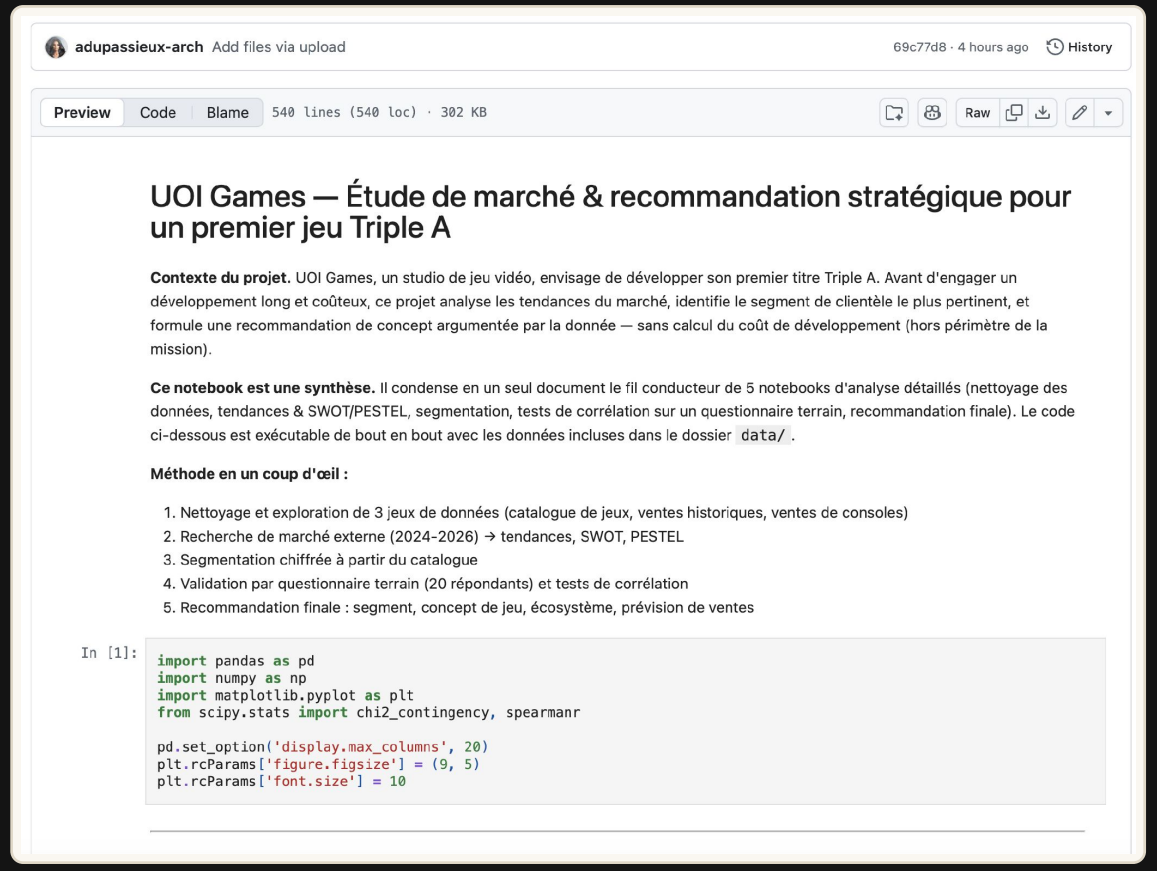
Vue d'ensemble : CA, marge, alertes filtrables par période



Vue Stock : les références à rotation la plus lente

ZOOM — LA DIVERSITÉ DES PREUVES

Du SQL au marché du jeu vidéo : des sujets très différents



adupassieux-arch Add files via upload — 69c77d8 · 4 hours ago — History

Preview | Code | Blame — 540 lines (540 loc) · 302 KB — Raw

UOI Games — Étude de marché & recommandation stratégique pour un premier jeu Triple A

Contexte du projet. UOI Games, un studio de jeu vidéo, envisage de développer son premier titre Triple A. Avant d'engager un développement long et coûteux, ce projet analyse les tendances du marché, identifie le segment de clientèle le plus pertinent, et formule une recommandation de concept argumentée par la donnée — sans calcul du coût de développement (hors périmètre de la mission).

Ce notebook est une synthèse. Il condense en un seul document le fil conducteur de 5 notebooks d'analyse détaillés (nettoyage des données, tendances & SWOT/PESTEL, segmentation, tests de corrélation sur un questionnaire terrain, recommandation finale). Le code ci-dessous est exécutable de bout en bout avec les données incluses dans le dossier `data/`.

Méthode en un coup d'œil :

1. Nettoyage et exploration de 3 jeux de données (catalogue de jeux, ventes historiques, ventes de consoles)
2. Recherche de marché externe (2024-2026) → tendances, SWOT, PESTEL
3. Segmentation chiffrée à partir du catalogue
4. Validation par questionnaire terrain (20 répondants) et tests de corrélation
5. Recommandation finale : segment, concept de jeu, écosystème, prévision de ventes

In [1]:

```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
from scipy.stats import chi2_contingency, spearmanr

pd.set_option('display.max_columns', 20)
plt.rcParams['figure.figsize'] = (9, 5)
plt.rcParams['font.size'] = 10
```

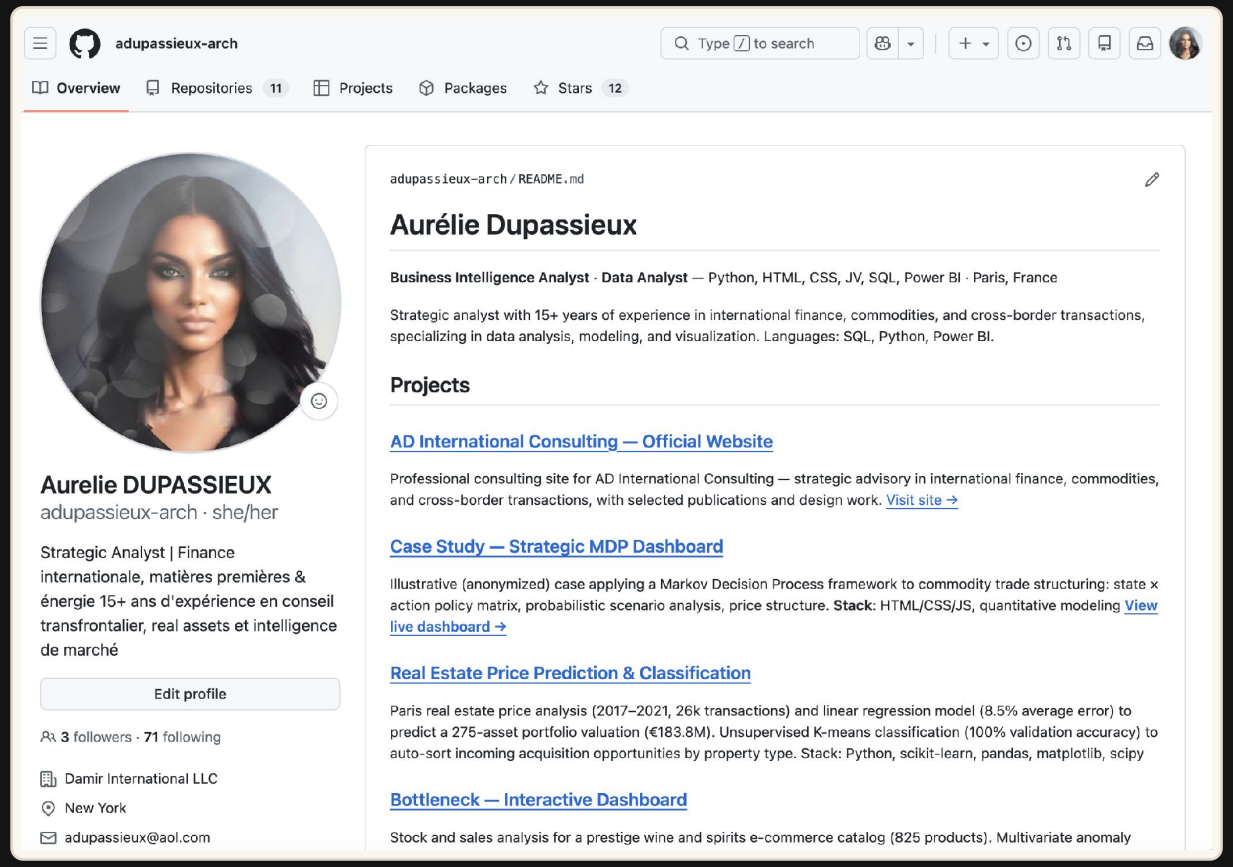
UOI Games — étude de marché et recommandation stratégique

Deux autres preuves du même registre

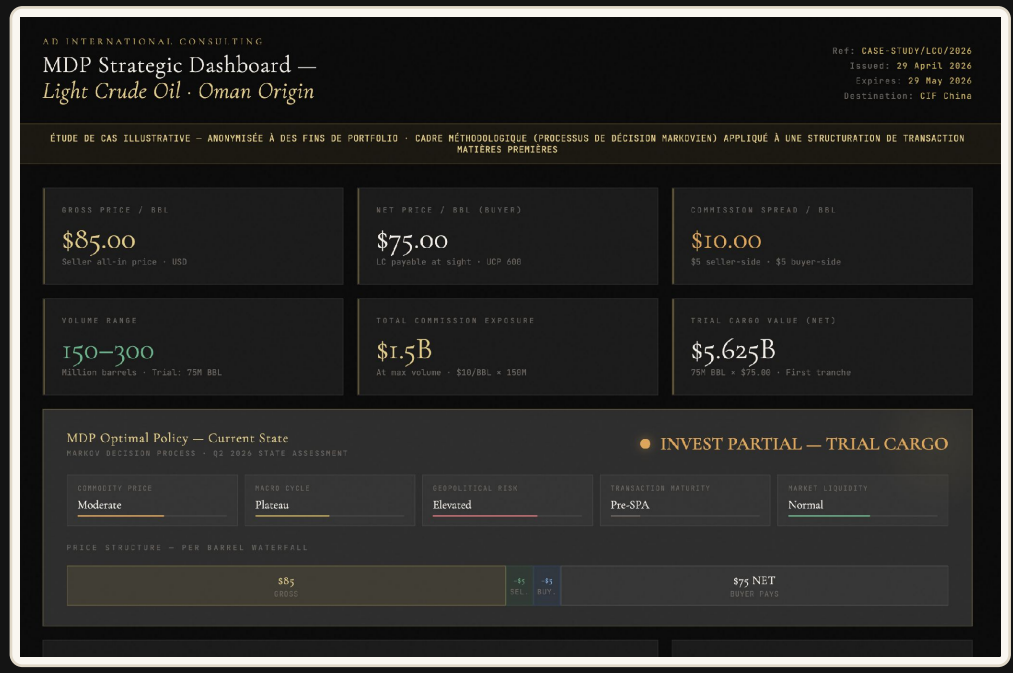
- SportDataPulse : short-list de recrutement pour un club de Ligue 1, à partir de requêtes SQL
- Mission RGPD : pseudonymisation de données personnelles pour un cabinet fictif

OÙ VOIR LE PORTFOLIO

Les preuves sont en ligne, pas seulement dans ce diaporama



Mon profil GitHub — README, 11 dépôts, 12 stars



Étude de cas MDP (Oman crude oil), anonymisée

github.com/adupassieux-arch

EN SYNTHÈSE

L'IA comme outil testé et maîtrisé — et un portfolio qui raconte une extension naturelle de mon parcours, pas seulement des projets.

Merci de votre attention

Questions & Discussion

Aurélie Dupassieux — Business Intelligence Analyst